

I - Définition, exemple


**Définition 1 :**  
On appelle série statistique à deux variables (ou série statistique doubles) une série statistique à deux caractères étudiés simultanément.

**Exemple 1 :**  
On a relevé, pour un modèle de voiture, la consommation en carburant (en L/100 km) pour différentes vitesses (en km/h) sur le cinquième rapport :

Vitesse $x_i$ (en km/h)	60	70	90	110	130	150
Consommation $y_i$ (en L/100 km)	3	3.1	3.7	4.7	6	9

**Définition 2 :**  
Dans un repère orthogonal, l'ensemble des points  $M_i$  de coordonnées  $(x_i, y_i)$  s'appelle le nuage de points.

**Exemple 2 :**  
Les points de l'exemple précédent forment le nuage de points suivant représenté dans le repère orthogonal ci-dessous.



II - Point moyen

**Définition 3 :**  
Le point moyen d'un nuage de points  $G$  de coordonnées  $(\bar{x}, \bar{y})$  où :

- $\bar{x}$  représente la moyenne des  $x_i$  :

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

- $\bar{y}$  représente la moyenne des  $y_i$  :

$$\bar{y} = \frac{y_1 + y_2 + \cdots + y_n}{n} = \frac{1}{n} \sum_{i=1}^n y_i$$

**Exemple 3 :**  
Le point moyen de l'exemple 1 est :

$$\begin{aligned}\overline{x} &= \frac{60 + 70 + 90 + 110 + 130 + 150}{6} = 101.66 \\ \overline{y} &= \frac{3 + 3.1 + 3.7 + 4.7 + 6 + 9}{6} = 4.75\end{aligned}$$

III - Ajustement affine par la méthode des moindres carrés

**Définition 4 :**  
On appelle covariance de  $x$  et de  $y$  le nombre :

$$\text{cov}(x, y) = \frac{1}{N} \sum_{i=1}^n (x_i - \overline{x})(y_i - \overline{y}) = \left( \frac{1}{N} \sum_{i=1}^n x_i y_i \right) - \overline{x} \overline{y}$$

**Définition 5 :**  
La variance du caractère  $x$  est :

$$V(x) = \frac{1}{N} \sum_{i=1}^n (x_i - \overline{x})^2 = \left( \frac{1}{N} \sum_{i=1}^n x_i^2 \right) - \overline{x}^2 = \text{cov}(x, x)$$

**Définition 6 :**  
La variance du caractère  $y$  est :

$$V(y) = \frac{1}{N} \sum_{i=1}^n (y_i - \overline{y})^2 = \left( \frac{1}{N} \sum_{i=1}^n y_i^2 \right) - \overline{y}^2 = \text{cov}(y, y)$$

**Définition 7 :**  
L'écart type de  $x$  est :

$$\sigma(x) = \sqrt{V(x)}$$

L'écart type de  $y$  est :

$$\sigma(y) = \sqrt{V(y)}$$

**Exemple 4 :**  
Calculons dans l'exemple 1 :  $\text{cov}(x, y)$ ,  $\text{cov}(x, x)$ ,  $\text{cov}(y, y)$ ,  $\sigma(x)$ ,  $\sigma(y)$ .  
On a :

$$\overline{x} = 101.66, \quad \overline{y} = 4.91$$

$x_i$	$y_i$	$x_i y_i$	$x_i^2$	$y_i^2$
60	3	180	3600	9
70	3.1	217	4900	9.61
90	3.7	333	8100	13.69
110	4.7	517	12100	22.09
130	6	780	16900	36
150	9	1350	22500	81
$\Sigma$		3377	68100	171.39

$$\text{cov}(x, y) = \frac{1}{N} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \frac{3377}{6} - 101.66 \times 4.91 = 63.68$$

$$V(x) = \frac{1}{N} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{68100}{6} - (101.66)^2 = 1015.2444$$

$$V(y) = \frac{1}{N} \sum_{i=1}^n y_i^2 - \bar{y}^2 = \frac{171.39}{6} - (4.91)^2 = 4.4569$$

$$\sigma(x) = \sqrt{V(x)} = \sqrt{1015.2444} = 31.86$$

$$\sigma(y) = \sqrt{V(y)} = \sqrt{4.4569} = 2.11$$

## IV - Théorème : Ajustement affine par la méthode des moindres carrés

### Théorème 1 :

Lors d'un ajustement affine par la méthode des moindres carrés :

1. La droite de régression  $D$  de  $Y$  en  $X$  a pour équation :

$$D(Y/X) : Y = aX + b$$

où :

$$a = \frac{\text{cov}(x, y)}{V(x)}, \quad b = \bar{Y} - a\bar{X}$$

Cette droite passe par le point moyen du nuage  $G(\bar{X}, \bar{Y})$ .

2. La droite de régression  $D$  de  $X$  en  $Y$  a pour équation :

$$D(X/Y) : X = a'Y + b'$$

où :

$$a' = \frac{\text{cov}(x, y)}{V(y)}, \quad b' = \bar{X} - a'\bar{Y}$$

Cette droite passe également par le point moyen du nuage  $G(\bar{X}, \bar{Y})$ .

### Exemple 5 :

Calculons dans l'exemple 1 les droites de régression :

- Droite de régression  $D(Y/X)$  :

$$a = \frac{\text{cov}(x, y)}{V(x)} = \frac{63.68}{1015.2444} = 0.0627$$

$$b = \bar{Y} - a\bar{X} = 4.91 - 0.0627 \times 101.66 = -1.46$$

Donc :

$$D(Y/X) : Y = 0.0627X - 1.46$$

- Droite de régression  $D(X/Y)$  :

$$a' = \frac{\text{cov}(x, y)}{V(y)} = \frac{63.68}{4.4569} = 14.287$$

$$b' = \bar{X} - a'\bar{Y} = 101.66 - 14.287 \times 4.91 = 31.51$$

Donc :

$$D(X/Y) : X = 14.287Y + 31.51$$

## V - Coefficient de corrélation linéaire

### Définition 8 :

Le coefficient de corrélation linéaire d'une série statistique à deux variables  $x$  et  $y$  est le nombre  $r$  défini par :

$$r = \frac{\text{cov}(x, y)}{\sqrt{V(x)}\sqrt{V(y)}} = \frac{\text{cov}(x, y)}{\sigma(x)\sigma(y)}$$

### Remarque 1 :

- $-1 \leq r \leq 1$ .
- Si  $r = 1$  ou  $r = -1$ , il y a une corrélation positive ou négative parfaite entre  $X$  et  $Y$ , et les points  $(x_i, y_i)$  sont tous sur la droite de régression.
- Si  $r = 0$ , il n'y a pas de corrélation entre  $X$  et  $Y$ , et les points  $(x_i, y_i)$  sont dispersés au hasard.
- Si  $0 < r < 1$ , il y a une corrélation positive faible, moyenne ou forte entre  $X$  et  $Y$ .
- Si  $-1 < r < 0$ , il y a une corrélation négative faible, moyenne ou forte entre  $X$  et  $Y$ .

### Exemple 6 :

Calculons dans l'exemple 1 le coefficient de corrélation linéaire :

$$\text{cov}(x, y) = 63.68, \quad \sigma(x) = 31.86, \quad \sigma(y) = 2.11$$

Donc :

$$r = \frac{\text{cov}(x, y)}{\sigma(x)\sigma(y)} = \frac{63.68}{31.86 \times 2.11} = 0.947$$

Il y a une corrélation positive forte entre  $X$  et  $Y$ .

## VI - Exercices d'application

### Exercice 1 :

Dans la série statistique suivante,  $X$  représente le nombre de jours d'exposition au soleil d'une feuille et  $Y$  le nombre de stomates aérifères au millimètre carré :

$X$	2	4	8	10	24	40	52
$Y$	6	11	15	20	39	62	85

1. Tracer le nuage des points.
2. Calculer le coefficient de corrélation linéaire entre  $X$  et  $Y$ . Conclusion ?
3. Déterminer l'équation de la droite de régression de  $Y$  en fonction de  $X$ .
4. Si on expose au soleil une feuille 15 jours, quel est le nombre de stomates aérifères peut-on prévoir ?

### Exercice 2 :

Dans la série statistique suivante,  $X$  représente le nombre d'heures d'étude par semaine et  $Y$  la note obtenue à un examen (sur 20) :

$X$	5	7	10	12	15	18	20
$Y$	8	10	12	14	16	18	20

1. Tracer le nuage des points.
2. Calculer le coefficient de corrélation linéaire entre  $X$  et  $Y$ . Conclusion ?
3. Déterminer l'équation de la droite de régression de  $Y$  en fonction de  $X$ .
4. Si un étudiant étudie 14 heures par semaine, quelle note peut-on prévoir ?